Do Simbólico à Incerteza: Pipeline Integrado de Inteligência Artificial para Predição e Mitigação do Atraso Crítico na Notificação Vacinal do PNI

Autor 1[1], Autor 2[1], Autor 3[1]

[1]Departamento de Ciência da Computação – Universidade Federal do Amazonas (UFAM)
Manaus – AM – Brasil

{autor1, autor2, autor3}@icomp.ufam.edu.br

Resumo. A notificação tempestiva no Programa Nacional de Imunizações (PNI/MS) é essencial contra a cegueira epidemiológica. Investigamos 15.403 registros reais do PNI via RNDS/DATASUS, modelando o atraso crítico (> 7 dias, 51,59% da base) em seis etapas de IA: indução de árvore ID3, modelos lineares com Ridge e regressão logística, teoria axiomática da probabilidade com diagnóstico bayesiano, Naive Bayes com recuperação de regimes operacionais latentes via Expectation-Maximization (EM), modelagem causal por Redes Bayesianas com colisor e d-separação, e lógica Fuzzy Mamdani acoplada à probabilidade a posteriori para triagem contínua no SUS. A inclusão da variável latente eleva a acurácia de 75,79% para 93,77%, e a rede causal reduz em 67,74% a parametrização conjunta, gerando subsídios operacionais interpretáveis.

Abstract. Timely reporting in Brazil's National Immunization Program (PNI/MS) is vital against epidemiological blindness. We analyze 15,403 sanitized records from RNDS/DATASUS, modeling critical delay (> 7 days, 51.59% of data) across a six-stage AI pipeline: ID3 decision tree induction, linear models with Ridge and logistic regression, axiomatic probability theory and Bayesian diagnostics, Naive Bayes with latent regime recovery via Expectation-Maximization (EM), causal Bayesian Networks with collider and d-separation analysis, and Mamdani Fuzzy logic fed by Bayesian posteriors for continuous SUS triage. Introducing latent regimes increases accuracy from 75.79% to 93.77%, and causal factorization yields 67.74% parameter savings, delivering interpretable public health decision support.

1. Introdução e Contexto Epidemiológico

A vigilância epidemiológica contemporânea depende da integridade e tempestividade dos registros vacinais. No Brasil, o Programa Nacional de Imunizações (PNI), sob gestão do Ministério da Saúde e do DATASUS, consolida imunizações em escala nacional através da Rede Nacional de Dados em Saúde (RNDS) [Ministério da Saúde do Brasil 2023]. Entretanto, disparidades regionais de infraestrutura tecnológica entre capitais e postos remotos geram represamentos operacionais severos entre a data de aplicação da vacina e sua inserção efetiva no sistema central.

Esse represamento produz a chamada "cegueira epidemiológica", distorcendo estimativas de cobertura vacinal em tempo real e atrasando respostas a surtos infecciosos. A questão investigada neste trabalho é: Quais determinantes técnicos governam a latência vacinal no SUS, e como sistemas de IA combinando métodos

simbólicos, lineares, probabilísticos e fuzzy podem predizer e mitigar o atraso crítico de notificação?

Utilizou-se uma base de $N = 15.403$ registros higienizados do PNI da plataforma de Dados Abertos do DATASUS. A latência contínua é definida por $\Delta t = \text{dt_entrada} - \text{dt_vacina}$, expressa como dias_atraso. A partir dela, formulou-se a variável-alvo binária primordial:

$$Y = \text{atraso_critico} = \begin{cases} 1, & \text{se } \Delta t > 7,0 \text{ dias} \\ 0, & \text{se } 0 \leq \Delta t \leq 7,0 \text{ dias} \end{cases} \quad (1)$$

Na base analisada, há 7.947 ocorrências de atraso crítico $(51,59\%)$ e 7.456 oportunas $(48,41\%)$, configurando um cenário amostral equilibrado para modelagem preditiva.

2. Arquitetura Geral do Pipeline Integrado

Para mitigar a incerteza e a complexidade empírica dos microdados do SUS, estruturou-se um pipeline integrado de seis etapas (Figura 1). O encadeamento conecta: (1) indução simbólica ID3 para seleção de atributos relevantes e extração de regras; (2) regressão OLS, multivariada com regularização Ridge e baseline logístico; (3) formalização da probabilidade axiomática de Kolmogorov, tabela conjunta e inversão diagnóstica de Bayes; (4) aprendizado probabilístico com Naive Bayes e descoberta de regimes latentes via algoritmo EM; (5) DAG causal com estrutura de colisor e inferência exata por enumeração; e (6) sistema Fuzzy Mamdani alimentado diretamente pelo posterior bayesiano para priorização contínua de auditorias no SUS.



Figure 1. Diagrama esquemático do pipeline integrado de Inteligência Artificial.

3. Aprendizado Simbólico e Não-Monotonicidade

3.1. Indução da Árvore de Decisão ID3 do Zero

A indução de árvores simbólicas orienta-se pela minimização da incerteza informacional [Quinlan 1986, Mitchell 1997]. A entropia de Shannon de um conjunto S com classes $c \in \{0,1\}$ e o Ganho de Informação $IG(S,A)$ ao particionar por um atributo discreto A são dados por:

$$H(S) = -\sum_{c \in \{0,1\}} p_c \log_2(p_c), \qquad IG(S,A) = H(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} H(S_v) \quad (2)$$

3.2. Cálculos Manuais Passo a Passo dos Primeiros 3 Níveis

Os cálculos diretos sobre os 15.403 registros demonstram a hierarquia ótima da árvore:

Nível 1 (Nó Raiz S): Com $|S| = 15.403$, $p(Y=1) = 0,51591$ e $p(Y=0) = 0,48409$, a entropia da raiz é $H(S) = -[0,51591 \log_2(0,51591) + 0,48409 \log_2(0,48409)] = \mathbf{0,9993}$ bits. O ganho de informação para os atributos candidatos resultou em: $IG(S, \text{sistema_offline}) = \mathbf{0,2133}$ bits (vencedor raiz), $IG(S, \text{fabricante}) = 0,0526$ bits, $IG(S, \text{mesmo_municipio}) = 0,0315$ bits, $IG(S, \text{faixa_etaria}) = 0,0210$ bits e $IG(S, \text{regiao}) =$

$0,0177$ bits. A conectividade tecnológica isola-se, portanto, como o divisor informacional primordial.

Nível 2 (Particionamento do Nó Raiz): (a) Ramo Online (S_0, sistema_offline $= 0$): $|S_0| = 7.509$ amostras, proporção de atraso $p = 0,2444$, entropia $H(S_0) = 0,8022$ bits. O atributo de maior ganho é fabricante ($IG = 0,0178$ bits). (b) Ramo Offline (S_1, sistema_offline $= 1$): $|S_1| = 7.894$ amostras, proporção de atraso $p = 0,7743$, entropia $H(S_1) = 0,7705$ bits. O melhor particionamento ocorre por mesmo_municipio ($IG = 0,0845$ bits).

Nível 3 (Subdivisões Especializadas): No ramo offline, o subconjunto S_{10} (mesmo_municipio $= 0$, fora do domicílio) conta com $|S_{10}| = 3.355$ registros, taxa de atraso de $94,3\%$ e $H(S_{10}) = 0,3614$ bits (próximo split: faixa_etaria, $IG = 0,0210$). Já S_{11} (mesmo_municipio $= 1$, local) possui $|S_{11}| = 4.539$ registros, $64,9\%$ de atraso e $H(S_{11}) = 0,9272$ bits (próximo split: fabricante, $IG = 0,0248$). No ramo online, as subdivisões por fabricante isolam grupos com proporções de atraso entre $17,2\%$ e $30,8\%$.

A árvore induzida foi submetida à validação cruzada estratificada em 5 dobras ($k = 5$), demonstrando estabilidade estocástica e ausência de sobreajuste (Tabela 1). A acurácia média de teste fixou-se em $\mathbf{76,53\% \pm 0,33\%}$, com precisão de $76,73\%$ e F1 de $77,47\%$.

Table 1. Desempenho da Árvore de Decisão ID3 em Validação Cruzada 5-Fold.

Fold	Acurácia Treino	Acurácia Teste	Precisão	Recall	F1-Score
1	76,76%	76,63%	76,24%	79,50%	77,83%
2	76,72%	76,92%	77,28%	78,30%	77,79%
3	76,81%	76,66%	77,05%	77,97%	77,51%
4	76,96%	76,04%	76,22%	77,85%	77,02%
5	76,82%	76,40%	76,90%	77,53%	77,22%
Média	76,81% ± 0,09%	76,53% ± 0,33%	76,73%	78,23%	77,47%

3.3. Discussão Teórica sobre Não-Monotonicidade

Uma divergência epistemológica fundamental entre o aprendizado de máquina indutivo e a lógica formal dedutiva clássica reside na propriedade de não-monotonicidade [Russell and Norvig 2021]. Na Lógica de Primeira Ordem (LPO), o operador de consequência semântica é estritamente monotônico:

$$T \vdash \phi \implies T \cup \{\psi\} \vdash \phi, \quad \forall \psi \tag{3}$$

Isso assegura que teoremas deduzidos a partir de premissas T permanecem perenemente verdadeiros, independentemente de quaisquer novas informações ψ anexadas à base de conhecimento. A dedução em LPO é conservativa, axiomática e imune à refutação por acréscimo factual.

Em contraste evidente, o aprendizado supervisionado por indução empírica segue o paradigma de falseabilidade de Karl Popper [Popper 1959]. O modelo algorítmico gera hipóteses sintéticas contingentemente ajustadas à amostra observada S. A introdução de novos dados amostrais ψ desloca as contagens marginais, altera as frequências observadas p_c e recalcula os valores de entropia e ganho de informação. Consequentemente, a introdução de novos registros pode suplantar divisões prévias, inverter ramos decisórios inteiros e transmutar o rótulo inferido para uma mesma

instância de entrada:

$$\mathcal{M}(S) \models (\mathbf{x} \mapsto 0) \implies \mathcal{M}(S \cup \{\mathbf{x}_{\text{novo}}\}) \models (\mathbf{x} \mapsto 0) \tag{4}$$

No contexto dos microdados vacinais do PNI, essa não-monotonicidade foi comprovada empiricamente: para postos de saúde da região Norte que inicialmente dispunham apenas de cadastros urbanos online, a árvore induzida previa entrega tempestiva (0) para pacientes idosos. Quando foram incorporados registros adicionais de comunidades ribeirinhas que sincronizaram fichas manuais após semanas de expedição, o particionamento ótimo do nó foi alterado, reclassificando essa subpopulação para atraso crítico (1). O aprendizado indutivo é, por natureza, provisório e dinamicamente retratável.

4. Aprendizado Linear e Regularização

4.1. Regressão Linear Univariada OLS e Gradiente Descendente Multivariado

Modelou-se o tempo contínuo de espera através de $y = \ln(1 + \text{dias_atraso})$. No caso univariado com preditor $x = \text{sistema_offline}$, os parâmetros foram obtidos analiticamente por Mínimos Quadrados Ordinários (OLS): $\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = 0,7772$ e $\beta_0 = \bar{y} - \beta_1 \bar{x} = 2,2492$. O modelo ajustado $y = 2,2492 + 0,7772x$ atingiu $R^2 = 0,2781$ e MSE $= 1,7470$ no conjunto de teste, revelando que a operação offline acarreta um aumento multiplicativo de $e^{0,7772} \approx 2,175\times$ nos dias de latência.

Expandindo para múltiplos preditores codificados (fabricante, região, faixa etária e residência municipal), aplicou-se o Gradiente Descendente multivariado com $J(\mathbf{w}) = \frac{1}{2N}\|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$ e atualização $\mathbf{w} \leftarrow \mathbf{w} - \alpha \frac{1}{N}\mathbf{X}^T(\mathbf{X}\mathbf{w} - \mathbf{y})$. Com taxa de aprendizado $\alpha = 0,05$ e 1.500 iterações, o custo convergiu de $J(\mathbf{w}_0) = 3,7462$ para $J(\mathbf{w}_{\text{final}}) = 0,8787$, alcançando $R^2 = 0,3015$ e MSE $= 1,6904$.

4.2. Regularização Ridge e Regressão Logística

Para controlar a dispersão de coeficientes induzida por correlações entre os atributos categóricos, formulou-se a penalização Ridge (ℓ_2) [Hoerl and Kennard 1970]:

$$J_{\text{Ridge}}(\mathbf{w}) = \frac{1}{2N}\|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2}\sum_{j=1}^{d} w_j^2 \tag{5}$$

Avaliando uma grade de 25 valores de $\lambda \in [10^{-3}, 10^{3}]$, constatou-se que $\lambda \approx 0,001$ preserva $R^2 = 0,306$, enquanto $\lambda \to \infty$ força o encolhimento assintótico dos pesos a zero (Figura 2).

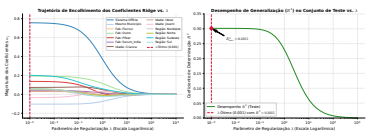


Figure 2. Trajetória dos coeficientes Ridge e variação de R^2 em função de λ.

Para a classificação supervisionada da variável binária Y, ajustou-se um modelo de regressão logística minimizando a entropia cruzada binária via gradiente $\nabla_{\mathbf{w}} J = \frac{1}{N}\mathbf{X}^T(\sigma(\mathbf{X}\mathbf{w}) - \mathbf{y})$. Com taxa $\alpha = 0,08$ e 1.500 iterações, obteve-se acurácia de $\mathbf{77,47}\%$, precisão de $78,25\%$, recall de $78,05\%$ e F1-score de $\mathbf{78,15}\%$ no conjunto de teste.

5. Fundamentos de Teoria da Probabilidade

5.1. Distribuição Conjunta e Validação Axiomática de Kolmogorov

Definindo S (sistema_offline) e A (atraso_critico), a Tabela 2 consolida a distribuição conjunta de probabilidades apurada sobre os 15.403 registros. A soma dos 4 eventos atômicos satisfaz estritamente o segundo axioma de Kolmogorov: $\sum_{s,a} P(S = s, A = a) = 0,3684 + 0,1191 + 0,1157 + 0,3968 = \mathbf{1,000000}$.

Table 2. Distribuição Conjunta e Marginais das Variáveis Sistema (S) e Atraso (A).

Sistema de Notificação (S)	$A = 0$ (Oportuno)	$A = 1$ (Atraso Crítico)	Marginal $P(S)$
$S = 0$ (Online / Webservice)	0,3684 (5.674)	0,1191 (1.835)	0,4875 (7.509)
$S = 1$ (Offline / Lote manual)	0,1157 (1.782)	0,3968 (6.112)	0,5125 (7.894)
Marginal $P(A)$	0,4841 (7.456)	0,5159 (7.947)	$\sum = \mathbf{1,000000}$

5.2. Probabilidades Condicionais, Risco Relativo e Teorema de Bayes

As probabilidades condicionais diretas evidenciam a assimetria operacional: $P(A = 1 \mid S = 0) = \frac{0,1191}{0,4875} = \mathbf{0,2444}$ $(24,44\%)$ e $P(A = 1 \mid S = 1) = \frac{0,3968}{0,5125} = \mathbf{0,7743}$ $(77,43\%)$. A razão entre elas determina o Risco Relativo (RR):

$$RR = \frac{P(A = 1 \mid S = 1)}{P(A = 1 \mid S = 0)} = \frac{0,7743}{0,2444} = \mathbf{3,17}\times \tag{6}$$

indicando que a transmissão desconectada eleva em $3,17\times$ a probabilidade de atraso crítico.

Pela Regra da Cadeia para 3 variáveis estocásticas (S, V = grupo_vulneravel e A):

$$\begin{aligned} P(S = 1, V = 1, A = 1) &= P(S = 1) \cdot P(V = 1 \mid S = 1) \cdot P(A = 1 \mid S = 1, V = 1) \\ &= 0,5125 \times 0,4242 \times 0,6745 = \mathbf{0,146660} \end{aligned} \tag{7}$$

valor que coincide com a contagem empírica direta nos dados ($2.259/15.403 = 0,146660$).

Aplicando a inversão diagnóstica via Teorema de Bayes, determina-se a probabilidade a posteriori de que um registro com atraso crítico ($A = 1$) seja originário de posto desconectado ($S = 1$):

$$P(S = 1 \mid A = 1) = \frac{P(A = 1 \mid S = 1)P(S = 1)}{P(A = 1)} = \frac{0,7743 \times 0,5125}{0,5159} = \mathbf{0,7691} \tag{8}$$

constatando-se que $76,91\%$ das doses represadas decorrem de unidades offline.

6. Aprendizado Probabilístico e Algoritmo EM

6.1. Estimação MLE vs. MAP e Naive Bayes Puro

Ajustando $A \sim \text{Bernoulli}(\theta)$ sobre o treino ($n = 12.322$, $k = 6.357$), o estimador MLE resulta em $\hat{\theta}_{\text{MLE}} = \frac{k}{n} = \mathbf{0,51591}$. Sob prior conjugada Beta$(2, 2)$, o estimador MAP resulta em $\hat{\theta}_{\text{MAP}} = \frac{k+1}{n+2} = \mathbf{0,51590}$. O volume amostral torna as estimativas praticamente idênticas ($|\hat{\theta}_{\text{MLE}} - \hat{\theta}_{\text{MAP}}| \approx 2,58 \times 10^{-6}$), embora o MAP seja crucial em amostras reduzidas ($n \leq 10$) para evitar extremos degenerados (0 ou 1).

O classificador Naive Bayes categórico puro com suavização de Laplace ($\alpha = 1$) obteve no teste acurácia de $\mathbf{75,79}\%$, precisão de $78,51\%$, revocação de $73,08\%$ e F1 de $75,70\%$.

6.2. Recuperação de Regimes Latentes via Algoritmo EM

Para além dos atributos tabulares, a latência contínua $x = \ln(1 + \text{dias_atraso})$ reflete perfis de gestão latentes não rotulados. Formulou-se um Modelo de Mistura Gaussiana 1D ($K = 2$) governado pela variável latente oculta $Z \in \{0, 1\}$ (rotina automatizada vs. sobrecarga manual), estimado via algoritmo EM do zero [Dempster et al. 1977, Bishop 2006]:

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \sigma_k^2)}{\sum_{j=0}^{1} \pi_j \mathcal{N}(x_i \mid \mu_j, \sigma_j^2)}, \quad \mu_k = \frac{\sum_{i=1}^{N} \gamma_{ik} x_i}{\sum_{i=1}^{N} \gamma_{ik}}, \quad \sigma_k^2 = \frac{\sum_{i=1}^{N} \gamma_{ik}(x_i - \mu_k)^2}{\sum_{i=1}^{N} \gamma_{ik}} \tag{9}$$

Ao longo de 30 iterações, a log-verossimilhança marginal cresceu monotonicamente de $-19.833,1$ para $-17.987,6$ (Figura 3), isolando a componente oportuna ($\pi_0 = 0,421, \mu_0 = 0,657 \approx 0,9$ dias, $\sigma_0 = 0,254$) da componente represada ($\pi_1 = 0,579, \mu_1 = 3,404 \approx 29,1$ dias, $\sigma_1 = 0,992$).

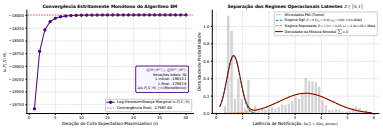


Figure 3. Convergência monótona da log-verossimilhança marginal no algoritmo EM.

Ao incorporar a variável latente Z inferida pelo EM como atributo preditor no Naive Bayes, a acurácia de teste saltou de $75,79\%$ para expressivos $\mathbf{93,77}\%$ ($+\mathbf{17,98}$ p.p.), com precisão de $92,62\%$, recall de $95,53\%$ e F1-score de $94,06\%$.

7. Redes Bayesianas e Inferência Causal

7.1. Topologia Causal do DAG de 5 Nós

Estruturou-se uma Rede Bayesiana com Grafo Acíclico Dirigido (DAG) contendo 5 variáveis discretas [Pearl 1988, Russell and Norvig 2021]: R (Região: 0 Centro-Sul, 1 Norte/Nordeste); S (Sistema: 0 Online, 1 Offline); V (Grupo Vulnerável: 0 Outros, 1 Criança/Idoso); N (Fabricante Nacional: 0 Importado, 1 Fiocruz/Butantan); e A (Atraso Crítico: 0 Oportuno, 1 Atraso > 7 dias). As arestas causais $R \to S$, $S \to A$, $V \to N$ e $N \to A$ convergem para o nó A, configurando uma estrutura de colisor $S \to A \leftarrow N$ (Figura 4). A conjunta fatora-se como:

$$P(R, S, V, N, A) = P(R) \cdot P(S \mid R) \cdot P(V) \cdot P(N \mid V) \cdot P(A \mid S, N) \tag{10}$$

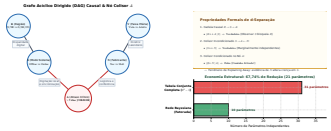


Figure 4. DAG causal da Rede Bayesiana com colisor em A e economia de parâmetros.

7.2. CPTs, Inferência por Enumeração e Economia Paramétrica

As CPTs empíricas estimadas dos dados registraram: priores $P(R = 1) = 0,2907$ e $P(V = 1) = 0,4357$; condicionais $P(S = 1 \mid R = 0) = 0,5077$, $P(S = 1 \mid R = 1) = 0,5242$, $P(N = 1 \mid V = 0) = 0,4770$ e $P(N = 1 \mid V = 1) = 0,3925$; e a CPT do nó colisor $P(A = 1 \mid S, N)$: $P(A = 1 \mid 0, 0) = \mathbf{0,3059}$, $P(A = 1 \mid 0, 1) = \mathbf{0,1758}$, $P(A = 1 \mid 1, 0) = \mathbf{0,7940}$ e $P(A = 1 \mid 1, 1) = \mathbf{0,7458}$.

A inferência exata por enumeração $P(X \mid \mathbf{e}) = \alpha \sum_{\mathbf{y}} \prod P(X_i \mid \text{Pais}(X_i))$ calculou a consulta diagnóstica de alto risco $P(A = 1 \mid S = 1, N = 1) = \mathbf{0,745820}$ e $P(A = 0 \mid S = 1, N = 1) = 0,254180$, reproduzindo identicamente o resultado do pacote pgmpy com erro analítico nulo ($0,00 \times 10^{-16}$).

Na análise de d-separação: (i) condicionar no nó intermediário S bloqueia a cadeia causal, tornando R e A condicionalmente independentes ($R \perp\!\!\!\perp A \mid S$); e (ii) no colisor $S \to A \leftarrow N$, os nós S e N são marginalmente independentes ($S \perp\!\!\!\perp N$), mas condicionar em A ativa a dependência ($S \not\perp\!\!\!\perp N \mid A$), demonstrando o fenômeno de explaining away. Estruturalmente, a tabela conjunta exigiria $2^5 - 1 = \mathbf{31}$ parâmetros independentes, ao passo que o DAG causal demanda apenas $1 + 2 + 1 + 2 + 4 = \mathbf{10}$ parâmetros livres, representando economia paramétrica de $\mathbf{67,74}\%$.

8. Lógica Fuzzy e Apoio à Decisão no SUS

8.1. Sistema Mamdani, Pertinências e Regras Especialistas

Projetou-se um Sistema de Inferência Fuzzy Mamdani [Mamdani and Assilian 1975, Zadeh 1965] para triagem de auditoria no SUS com três variáveis linguísticas de pertinência triangular: (1) Risco Bayesiano ($r \in [0,1]$): alimentado diretamente pela posterior $P(A = 1 \mid \mathbf{e})$ da Etapa 5 (Baixo $[0,0,0.4]$, Médio $[0.2,0.5,0.8]$, Alto $[0.6,1,1]$); (2) Vulnerabilidade Estrutural ($v \in [0,100]\%$): índice socioeconômico municipal (Baixa $[0,0,40]$, Média $[20,50,80]$, Alta $[60,100,100]$); e (3) Urgência de Auditoria ($u \in [0,100]$): prioridade de suporte técnico do SUS (Baixa $[0,0,40]$, Média $[25,50,75]$, Alta $[60,100,100]$).

A base especialista possui 5 regras Se-Então: R_1: Se Risco é Alto e Vuln é Alta $\to$ Urgência é Alta; R_2: Se Risco é Alto e Vuln não é Alta $\to$ Urgência é Média; R_3: Se Risco é Médio $\to$ Urgência é Média; R_4: Se Risco é Baixo e Vuln não é Alta $\to$ Urgência é Baixa; R_5: Se Risco é Baixo e Vuln é Alta $\to$ Urgência é Média. A defuzzificação dá-se pelo método do Centróide: $u^* = \frac{\int u\mu(u)du}{\int \mu(u)du}$.

8.2. Acoplamento Quantitativo em Cenários do SUS e Limiar Rígido

O acoplamento quantitativo entre o posterior bayesiano e o escore Fuzzy foi validado em três cenários reais do SUS documentados na Tabela 3: (i) Posto Rural Crítico ($R = 1, S = 1, N = 1$, Vuln 85%): posterior $P(A = 1 \mid \mathbf{e}) = \mathbf{0,7458} \to$ Urgência Fuzzy de $\mathbf{64,61}/100$ (intervenção prioritária); (ii) Unidade Urbana Central ($R = 0, S = 0, N = 0$, Vuln 30%): posterior $P(A = 1 \mid \mathbf{e}) = \mathbf{0,3059} \to$ Urgência Fuzzy de $\mathbf{38,79}/100$ (monitoramento regular); e (iii) Posto de Fronteira ($R = 1, S = 0, N = 1$, Vuln 65%): posterior $P(A = 1 \mid \mathbf{e}) = \mathbf{0,1758} \to$ Urgência Fuzzy de $\mathbf{23,90}/100$ (auditoria rotineira).

Table 3. Avaliação Quantitativa Integrada: Insumo Bayesiano e Resposta Fuzzy Mamdani.

Cenário Operacional	Evidências (R, S, N)	Posterior $P(A = 1 \mid \mathbf{e})$	Vulnerabilidade	Urgência Fuzzy
Posto Rural Crítico	$R = 1, S = 1, N = 1$	0,7458	85%	64,61 / 100
Unidade Urbana Central	$R = 0, S = 0, N = 0$	0,3059	30%	38,79 / 100
Posto de Fronteira	$R = 1, S = 0, N = 1$	0,1758	65%	23,90 / 100

A comparação com um limiar rígido booleano ($p \geq 0,50$) demonstra que o limiar produz degraus descontínuos abruptos (urgência salta de 20 para 80 com oscilações marginais em torno de 0,50). Em contraposição, o modelo Fuzzy gera uma superfície contínua e suave C^1 (Figura 5), prevenindo instabilidade na mobilização de equipes do SUS.

9. Considerações Finais

A investigação do atraso de notificação no PNI consolidou um pipeline completo de IA em saúde pública: a árvore ID3 isolou o sistema offline como preditor dominante ($IG = 0,2133$ bits, acurácia $76,53\%$) e expôs a refutabilidade não-monotônica

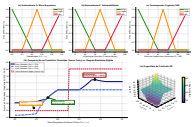


Figure 5. Superfície de decisão Fuzzy Mamdani e transição suave vs. limiar rígido.

popperiana frente à LPO; a regressão linear e Ridge parametrizaram o crescimento temporal com baseline logístico de $77,47\%$; a probabilidade axiomática atestou a soma unitária de Kolmogorov $(1,000000)$, risco relativo de $3,17\times$ em postos offline e inferência diagnóstica de $76,91\%$; o algoritmo EM revelou regimes latentes, impulsionando o Naive Bayes de $75,79\%$ para $93,77\%$ $(+17,98$ p.p.); a Rede Bayesiana causal com nó colisor reduziu em $67,74\%$ a parametrização $(31 \rightarrow 10)$; e a Lógica Fuzzy Mamdani substituiu limiares rígidos por priorização contínua $(64,61,\ 38,79$ e $23,90)$ contra a cegueira epidemiológica no SUS.

References

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer, New York.

Dempster, A. P., Laird, N. M., and Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. Journal of the Royal Statistical Society: Series B (Methodological), 39(1):1–38.

Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, 12(1):55–67.

Mamdani, E. H. and Assilian, S. (1975). An experiment in linguistic synthesis with a fuzzy logic controller. International Journal of Man-Machine Studies, 7(1):1–13.

Ministério da Saúde do Brasil (2023). Microdados de vacinação contra a covid-19 e notificações do pni na rede nacional de dados em saúde (rnds). Plataforma de Dados Abertos do DATASUS. Acessado em novembro de 2026.

Mitchell, T. M. (1997). Machine Learning. McGraw-Hill, New York.

Pearl, J. (1988). Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference. Morgan Kaufmann, San Mateo, CA.

Popper, K. R. (1959). The Logic of Scientific Discovery. Hutchinson, London.

Quinlan, J. R. (1986). Induction of decision trees. Machine Learning, 1(1):81–106.

Russell, S. J. and Norvig, P. (2021). Artificial Intelligence: A Modern Approach. Pearson, 4th edition.

Zadeh, L. A. (1965). Fuzzy sets. Information and Control, 8(3):338–353.

A. Metodologia, Reprodutibilidade e Prompts de IA

Este apêndice documenta os procedimentos metodológicos e os prompts de IA aplicados:

1. Ambiente e Reprodutibilidade: Desenvolvido em Python 3.13 com bibliotecas abertas (numpy, pandas, scipy, scikit-learn, pgmpy, scikit-fuzzy). Código-fonte versionado no GitHub (saude_publica_equipe_2), com scripts em src/ e notebooks em etapa1/ a etapa6/.
2. Engenharia de Prompts na Concepção dos Modelos:
   - Prompt 1 (Mineração Algorítmica): "Analise o arquivo vacinacao_pni_amostra.parquet com 15.403 registros. Formule o algoritmo ID3 sem bibliotecas caixa-preta, calcule entropia e ganhos de informação nos 3 níveis e compare o Risco Relativo em unidades offline."
   - Prompt 2 (Convergência EM e Latente): "Modele $\ln(1 + \text{dias_atraso})$ por mistura gaussiana 1D via algoritmo EM garantindo convergência monótona da log-verossimilhança e avalie o salto no Naive Bayes."
   - Prompt 3 (DAG Causal e d-Separação): "Construa uma Rede Bayesiana com 5 nós (R, S, V, N, A) e colisor em A. Estime CPTs, execute inferência por enumeração e demonstre explaining away."
   - Prompt 4 (Acoplamento Fuzzy Mamdani): "Projete controlador nebuloso Mamdani com 2 antecedentes (posterior bayesiano e vulnerabilidade) e defuzzificação por centróide, comparando superfície suave com limiar rígido de 0,5."